

Práctica 3: Aprendizaje por Refuerzo

Dennis García Solera

DNI: 20514351F

Universidad de Alicante – Escuela Politécnica Superior

Aprendizaje Avanzado – Curso 2025/2026

Email: dgs75@alu.ua.es

Resumen

*En esta práctica he implementado y comparado tres enfoques de Aprendizaje por Refuerzo sobre el entorno **LunarLander-v3** de Gymnasium, formalizado como un Proceso de Decisión de Markov con espacio de estados continuo de 8 dimensiones y 4 acciones discretas. Partiendo de una política aleatoria como referencia de dificultad (recompensa media de $-183,18$), he entrenado el algoritmo REINFORCE puro (gradiente de política de Monte Carlo) y su variante con línea base (arquitectura Actor-Crítico), explorando además dos mejoras opcionales (normalización de retornos/ventajas y bonus de entropía) con dos calibraciones del peso de la entropía. El resultado principal es contundente: mientras REINFORCE puro no logra resolver el entorno (recompensa media de $-39,90$), la introducción de la línea base lo transforma en un agente que aterriza con éxito en el 87 % de los episodios de evaluación (recompensa media de $237,06$, por encima del umbral de 200). El hallazgo más instructivo es que las mejoras opcionales no siempre mejoran: un bonus de entropía excesivo ($\beta = 0,01$) induce un óptimo local de “flotar sin aterrizar” que degrada el rendimiento, problema que se corrige reduciendo el coeficiente a $\beta = 0,001$.*

Índice

1. Ejercicio 1: Política Aleatoria	2
1.1. Implementación del Bucle de Interacción	2
1.2. Resultados	2
1.3. Análisis	3
2. Ejercicio 2: REINFORCE	3
2.1. Fase A: Entrenamiento	3
2.1.1. Hiperparámetros y Justificación	3
2.1.2. Resultados del Entrenamiento	4
2.2. Fase B: Evaluación	4
2.3. Tarea Opcional: Mejoras sobre REINFORCE	5
2.3.1. Normalización de Retornos	5
2.3.2. Bonus de Entropía	5
3. Ejercicio 3: REINFORCE con Línea Base	7
3.1. Fase A: Entrenamiento	7
3.1.1. Hiperparámetros y Justificación	7
3.1.2. Resultados del Entrenamiento	7
3.2. Fase B: Evaluación	8
3.3. Tarea Opcional: Mejoras sobre REINFORCE con Línea Base	9
3.3.1. Normalización de Ventajas	9
3.3.2. Bonus de Entropía	9
4. Comparación Global	11
5. Conclusiones	12

1. Ejercicio 1: Política Aleatoria

1.1. Implementación del Bucle de Interacción

Se implementó el bucle básico de interacción agente-entorno durante 100 episodios consecutivos, donde el agente selecciona acciones de forma puramente aleatoria mediante `env.action_space.sample()`.

El entorno se instancia mediante `gym.make` con el identificador `LunarLander-v3` y el modo de renderizado `rgb_array`, para poder capturar fotogramas. Cada episodio se reinicia con una semilla distinta pero reproducible (`seed + ep`), de modo que las perturbaciones iniciales aleatorias varían entre episodios sin perder la reproducibilidad global. En cada paso se acumula la recompensa devuelta por `env.step()` y se cuenta el número de transiciones hasta que el entorno señala `terminated` (la nave aterriza o se estrella) o `truncated` (límite de pasos). Al finalizar cada episodio se almacenan la recompensa acumulada y la duración para su posterior análisis estadístico.

1.2. Resultados

Tabla 1: Estadísticas de la política aleatoria (100 episodios)

Métrica	Media	Desv. Estándar
Recompensa acumulada	-183,18	119,75
Duración (pasos)	90,34	19,00




Figura 1: Evolución de métricas – política aleatoria (100 episodios). Izquierda: recompensa acumulada por episodio, con media $-183,18$ y banda ± 1 desviación estándar. Derecha: duración en pasos. La línea roja marca el umbral de resolución (200 puntos), inalcanzable para el agente aleatorio.




Figura 2: Fotograma representativo del agente aleatorio. La nave se aproxima al suelo de forma descontrolada, sin orientar su descenso hacia la plataforma de aterrizaje entre las balizas.

1.3. Análisis

La política aleatoria es ineficaz porque cada acción se muestrea de forma uniforme e **independiente del estado**: no existe correlación alguna entre la situación cinemática de la nave (posición, velocidad, ángulo) y el motor que se acciona. El agente no puede, por tanto, contrarrestar la inercia ni la gravedad de forma coherente, ya que encender el motor principal o los laterales en el momento equivocado es tan probable como hacerlo en el correcto.

En la visualización (Figura 2) se aprecian los comportamientos erráticos típicos: giros descontrolados por el encendido arbitrario de los motores de orientación, ausencia de cualquier intento de estabilizar el ángulo de la nave, y un consumo de combustible que penaliza la recompensa sin aportar control. La mayoría de episodios terminan en choque o salida de los límites, lo que explica la corta duración media (apenas 90,34 pasos): el agente alcanza rápidamente un estado terminal por estrellarse.

Cuantitativamente, la recompensa media de $-183,18$ se sitúa a una distancia de **más de 383 puntos** del umbral de 200 necesario para considerar el entorno resuelto. Ningún episodio se acerca siquiera a valores positivos de forma consistente (el máximo aislado ronda los 20 puntos). Esta enorme brecha cuantifica la dificultad intrínseca del problema y establece la referencia objetiva contra la que mediremos la mejora aportada por los métodos de aprendizaje en los ejercicios siguientes.

2. Ejercicio 2: REINFORCE

2.1. Fase A: Entrenamiento

2.1.1. Hiperparámetros y Justificación

Tabla 2: Hiperparámetros seleccionados para REINFORCE

Hiperparámetro	Valor	Justificación
Tasa de aprendizaje (α)	10^{-3}	Valor robusto para MLPs pequeños con Adam; equilibra velocidad y estabilidad.
Factor de descuento (γ)	0,99	Las recompensas clave (aterrizaje +100, contacto de patas +10) son tardías; valora fuertemente el futuro.
Neuronas ocultas (<code>n_hidden</code>)	128	Capacidad suficiente para el mapeo $8 \rightarrow 4$ no lineal sin sobreparametrizar.
Optimizador	Adam	Tasas adaptativas por parámetro que toleran la alta varianza del gradiente.
Recorte de gradiente	1,0	Evita pasos destructivos ante retornos atípicos.
Número de episodios	2000	Ampliado respecto a los 1000 de partida: Monte Carlo necesita margen para converger.

La elección de **Adam** frente a SGD responde a la naturaleza del gradiente de REINFORCE, que presenta una varianza muy elevada al depender del retorno de trayectorias completas. Las tasas de aprendizaje adaptativas por parámetro de Adam amortiguan esa varianza y permiten un avance estable sin necesidad de un ajuste fino del paso, algo que un SGD plano gestiona mucho peor en este escenario.

Respecto a la **tasa de aprendizaje**, un valor demasiado alto provoca que cada paso de gradiente modifique la política de forma excesiva: la red “salta” sobre las regiones de buen rendimiento, la pérdida oscila violentamente y, en el peor caso, los logits divergen hasta producir NaN. Un valor demasiado bajo, en cambio, hace que el aprendizaje sea tan lento que no se alcanza una política competente dentro del presupuesto de episodios. El valor $\alpha = 10^{-3}$ se sitúa en el punto de equilibrio empírico para esta arquitectura.

El **factor de descuento** es crítico en este entorno por la estructura temporal de la recompensa. Las señales más valiosas (el +100 por aterrizar, el +10 por cada pata en contacto) llegan al **final** del episodio. Con γ cercano a 0 el agente se vuelve completamente **miope**: solo pondera la recompensa

inmediata y es incapaz de aprender que una secuencia de maniobras de frenado, costosas a corto plazo por el consumo de combustible, conduce a una gran recompensa terminal. Con $\gamma = 0,99$ el horizonte efectivo es lo bastante largo como para propagar el valor del aterrizaje hacia las decisiones tempranas del descenso.

2.1.2. Resultados del Entrenamiento

Tabla 3: Estadísticas del entrenamiento REINFORCE (2000 episodios)

Métrica	Media	Desv. Estándar
Recompensa acumulada	-227,24	175,42
Duración (pasos)	143,38	81,45




Figura 3: Curvas de entrenamiento – REINFORCE puro (2000 episodios). La media móvil (negro) revela una tendencia ascendente muy ruidosa que solo se acerca a valores positivos en los últimos cientos de episodios.

La curva de entrenamiento (Figura 3) muestra una **tendencia creciente clara pero extraordinariamente ruidosa**. La media móvil parte de valores en torno a -200 y solo en la fase final del entrenamiento (a partir del episodio ~ 1800) la recompensa logra acercarse de forma sostenida a cero. La varianza es altísima: la banda ± 1 desviación estándar es de 175,42, y se observan caídas puntuales por debajo de -1000 incluso en fases avanzadas.

Este comportamiento es la **firma característica de la alta varianza de REINFORCE vanilla**: al escalar el gradiente por el retorno absoluto de la trayectoria completa, un único episodio con una mala racha de acciones penaliza indiscriminadamente a todas las decisiones de ese episodio, incluidas las buenas. El agente no llega a converger de forma estable, y **no alcanza los 200 puntos en ningún momento del entrenamiento**: la media móvil final apenas roza el cero. Esto evidencia que, aunque el gradiente de política sí aprende (la mejora respecto al -227 inicial es real), el método puro carece de la estabilidad necesaria para dominar el entorno en el presupuesto disponible.

2.2. Fase B: Evaluación

Tabla 4: Estadísticas de evaluación – REINFORCE (100 episodios)

Métrica	Media	Desv. Estándar
Recompensa acumulada	-39,90	50,90
Duración (pasos)	126,00	43,53

La evaluación con los mejores pesos arroja una recompensa media de $-39,90$, lo que supone una **mejora de unos 143 puntos** respecto al agente aleatorio ($-183,18$). El gradiente de política ha

Ejercicio 2 — REINFORCE puro (evaluación, 100 episodios)




Figura 4: Evaluación – REINFORCE puro (100 episodios). La recompensa se concentra en torno a -40 , sin superar nunca el umbral de 200.




Figura 5: Fotograma del agente REINFORCE. La nave mantiene una orientación más controlada que el agente aleatorio, pero aún no logra un aterrizaje suave y preciso sobre la plataforma.

transformado, por tanto, un comportamiento puramente errático en uno con cierta intencionalidad: el agente ha aprendido a estabilizar parcialmente la nave y a evitar muchos de los choques inmediatos, como refleja también la menor dispersión en evaluación (50,90 frente a 119,75 del aleatorio).

Sin embargo, el agente **no aterriza de forma consistente** y **no supera en ningún episodio el umbral de 200 puntos** (Figura 4). La recompensa media negativa indica que, si bien evita el desastre, no completa la tarea: la nave llega a las proximidades del suelo pero no consigue posarse de forma controlada entre las balizas. En términos del Principio del Máximo de Pontryagin, ha aprendido a no malgastar combustible de forma catástrofica, pero no la política fina de frenado que requiere el aterrizaje. Esta limitación es precisamente la que motiva la introducción de la línea base en el Ejercicio 3.

2.3. Tarea Opcional: Mejoras sobre REINFORCE

2.3.1. Normalización de Retornos

Se implementó la normalización estandarizando el tensor de retornos descontados de cada episodio (resta de la media y división por la desviación estándar, con un $\epsilon = 10^{-8}$ de estabilidad numérica) antes de multiplicarlo por el logaritmo de las probabilidades. Esto reduce la escala y la varianza del gradiente, evitando que episodios con retornos de gran magnitud dominen la actualización.

2.3.2. Bonus de Entropía

Se añadió a la pérdida un término $-\beta H(\pi)$ que premia las políticas inciertas, fomentando la exploración y retrasando la convergencia prematura. El coeficiente β **decae linealmente** a lo largo

del entrenamiento, de modo que el agente explora al principio y se vuelve más determinista al final. Se probaron dos calibraciones: $\beta = 0,01$ (entropía alta) y $\beta = 0,001$ (entropía baja).




Figura 6: Comparación de las tres configuraciones del Ejercicio 2 (media móvil de 50 episodios). Ambas variantes mejoradas superan ampliamente a REINFORCE puro, situándose de forma sostenida cerca del cero.

Tabla 5: Evaluación de las tres configuraciones de REINFORCE (100 episodios)

Configuración	Recomp. Media	Duración Media	Resuelto
REINFORCE puro	-39,90	126,00	0 %
Mejorado, entropía alta ($\beta = 0,01$)	118,64	957,72	0 %
Mejorado, entropía baja ($\beta = 0,001$)	104,08	775,28	0 %

Las mejoras tienen un **efecto muy positivo sobre la recompensa media**, que pasa de $-39,90$ (puro) a $+118,64$ (entropía alta) y $+104,08$ (entropía baja). La combinación de normalización y entropía lleva la media móvil de entrenamiento de forma sostenida por encima del cero (Figura 6), algo que la versión pura nunca consiguió. La normalización cumple su función de estabilización y el bonus de entropía mantiene la exploración suficiente para escapar de políticas tempranas subóptimas.

No obstante, aquí aparece un fenómeno revelador que conviene analizar con honestidad: **ninguna de las dos variantes resuelve el entorno** (ambas con 0 % de episodios sobre 200) y, sobre todo, presentan duraciones de episodio enormes (957 y 775 pasos frente a los 126 del puro). Esto indica que el agente ha aprendido a **flotar**: mantiene la nave suspendida en el aire evitando estrellarse (esquiva el -100) pero sin comprometerse al aterrizaje (renuncia al $+100$). El bonus de entropía, al premiar la indecisión de la política, contribuye a este comportamiento. La diferencia entre $\beta = 0,01$ y $\beta = 0,001$ ya apunta en la dirección correcta (la entropía más baja reduce la duración de 957 a 775 pasos), un efecto que se hará mucho más evidente en el Ejercicio 3 con la línea base. La conclusión parcial es que, sin una señal de ventaja informativa, REINFORCE no dispone de la precisión necesaria para resolver el aterrizaje, por muy depuradas que estén las mejoras.

3. Ejercicio 3: REINFORCE con Línea Base

3.1. Fase A: Entrenamiento

3.1.1. Hiperparámetros y Justificación

Tabla 6: Hiperparámetros – REINFORCE con línea base

Hiperparámetro	Valor	Justificación
α_{actor} (PolicyNetwork)	10^{-3}	Igual que en REINFORCE; la política es la parte delicada.
$\alpha_{\text{crítico}}$ (ValueNetwork)	3×10^{-3}	Más alta: el crítico debe converger rápido para dar ventajas fiables.
Pasos de crítico por episodio	5	Varias actualizaciones de $V(s)$ por episodio para que alcance el objetivo.
Factor de descuento (γ)	0,99	Mismas razones que en el Ejercicio 2.
Neuronas ocultas (<code>n_hidden</code>)	128	Misma arquitectura para Actor y Crítico.
Optimizador (Actor)	Adam	Robusto frente a la varianza del gradiente de política.
Optimizador (Crítico)	Adam	Regresión estable de $V(s)$ hacia el retorno.
Número de episodios	2000	Margen suficiente para converger por encima de 200.

El Actor y el Crítico **no deben aprender a la misma velocidad**. He fijado la tasa del Crítico (3×10^{-3}) por encima de la del Actor (10^{-3}), y además realizo **cinco pasos de gradiente del Crítico por episodio**. La razón es la dependencia jerárquica entre ambas redes: el Actor se actualiza usando la ventaja $A_t = G_t - V_\phi(s_t)$, que es informativa solo si la estimación de valor V_ϕ es fiable. El Crítico resuelve un problema de **regresión supervisada** (ajustar $V(s)$ a G_t), intrínsecamente más estable que la optimización de política, por lo que puede y debe ir por delante.

Si el Crítico aprende **demasiado lento**, las ventajas son ruidosas: el Actor recibe señales de “mejor o peor de lo esperado” basadas en una expectativa $V(s)$ todavía errónea, y aprende sobre información defectuosa (este fue precisamente el problema de una implementación inicial con un único paso de crítico, que neutralizaba el beneficio de la línea base). Si aprende **demasiado rápido**, puede sobreajustar a los retornos de los últimos episodios e introducir inestabilidad. El equilibrio elegido (crítico más rápido y con varios pasos, pero con recorte de gradiente) garantiza ventajas informativas sin desestabilizar el conjunto.

3.1.2. Resultados del Entrenamiento

Tabla 7: Estadísticas del entrenamiento – REINFORCE con línea base (2000 episodios)

Métrica	Media	Desv. Estándar
Recompensa acumulada	93,95	160,23
Duración (pasos)	358,60	311,67

La línea base supone un **salto cualitativo** respecto a REINFORCE puro. La media de recompensa en entrenamiento pasa de $-227,24$ a $+93,95$, y la media móvil cruza de forma sostenida el umbral de 200 a partir del episodio ~ 900 (Figura 7), un hito que la versión pura no alcanzó en ningún momento. La convergencia es, por tanto, mucho más rápida y efectiva.

Conviene, no obstante, ser preciso con la cuestión de la varianza. La desviación estándar de la recompensa de entrenamiento es de 160,23, **solo ligeramente inferior** a los 175,42 de REINFORCE puro. Es decir, la línea base **redujo la varianza de forma modesta**, no espectacular. Este matiz es importante: el beneficio principal de la línea base en este experimento no ha sido tanto suavizar la curva como **volver informativa la señal de aprendizaje**. Al sustituir el retorno absoluto G_t por la ventaja $A_t = G_t - V(s_t)$, el agente deja de preguntarse “¿fue buena la trayectoria?” para preguntarse

Ejercicio 3 — REINFORCE con línea base (entrenamiento)




Figura 7: Curvas de entrenamiento – REINFORCE con línea base (2000 episodios). La media móvil cruza de forma sostenida el umbral de 200 a partir del episodio ~900, algo que REINFORCE puro nunca logró.

“¿fue esta acción mejor de lo esperado desde este estado?”, una señal mucho más precisa que es la que realmente desbloquea el aprendizaje del aterrizaje, aunque la dispersión episodio a episodio siga siendo alta por la naturaleza Monte Carlo del método.

3.2. Fase B: Evaluación

Tabla 8: Estadísticas de evaluación – REINFORCE con línea base (100 episodios)

Métrica	Media	Desv. Estándar
Recompensa acumulada	237,06	76,93
Duración (pasos)	271,65	71,12

Ejercicio 3 — REINFORCE con línea base (evaluación)




Figura 8: Evaluación – REINFORCE con línea base (100 episodios). La inmensa mayoría de episodios superan el umbral de 200 puntos (media 237,06, 87 % resueltos).

El resultado de la evaluación es el **hallazgo central de la práctica**: una recompensa media de 237,06, por encima del umbral de 200, con un 87 % de episodios resueltos. Frente al -39,90 de REINFORCE puro, la mejora es de más de 276 puntos, y frente al agente aleatorio supera los 420 puntos de diferencia. El agente ha pasado de no resolver nunca el entorno a aterrizar con éxito en la gran mayoría de los intentos.

El comportamiento es cualitativamente distinto (Figura 9): la nave desciende de forma orientada y controlada, frena su caída con el motor principal en el momento adecuado y se posa entre las balizas. La duración media de 271,65 pasos es coherente con un aterrizaje deliberado (ni los choques inmediatos del aleatorio, ni el flotado indefinido de las variantes con entropía alta del Ejercicio 2). Los pocos




Figura 9: Fotograma del agente con línea base. La nave desciende de forma controlada y orientada hacia la plataforma de aterrizaje entre las balizas.

episodios fallidos que arrastran la cola inferior de la distribución explican la desviación de 76,93, pero el grueso de la masa de probabilidad se concentra claramente sobre los 200 puntos.

3.3. Tarea Opcional: Mejoras sobre REINFORCE con Línea Base

3.3.1. Normalización de Ventajas

Análogamente al Ejercicio 2, se normalizó el tensor de ventajas A_t de cada episodio (media 0, desviación 1). Esta operación es especialmente natural sobre la ventaja, pues la centra en cero y escala su dispersión, estabilizando aún más el gradiente del Actor. El Crítico, en cambio, se sigue entrenando contra los retornos **sin normalizar**, ya que su objetivo es predecir el retorno real.

3.3.2. Bonus de Entropía

Se añadió el mismo término de entropía decreciente a la pérdida del Actor, con las dos calibraciones $\beta = 0,01$ y $\beta = 0,001$.




Figura 10: Comparación de las tres configuraciones del Ejercicio 3 (media móvil de 50 episodios). El baseline obligatorio y la variante de entropía baja convergen por encima de 200; la de entropía alta se estanca más abajo.

Tabla 9: Evaluación de las tres configuraciones del Ejercicio 3 (100 episodios)

Configuración	Recomp. Media	Duración Media	Resuelto
Baseline obligatorio	237,06	271,65	87 %
Mejorado, entropía alta ($\beta = 0,01$)	157,22	706,47	37 %
Mejorado, entropía baja ($\beta = 0,001$)	228,32	295,72	84 %

Este apartado contiene el **aprendizaje más instructivo de la práctica**: *las mejoras opcionales no siempre mejoran*. La variante con **entropía alta** ($\beta = 0,01$) rinde **peor** que el baseline obligatorio sin mejoras: su recompensa cae de 237,06 a 157,22 y el porcentaje de resolución se desploma del 87 % al 37 %. La clave está en la duración: 706 pasos frente a 272. De nuevo aparece el comportamiento de **flotar sin aterrizar**: un bonus de entropía demasiado fuerte mantiene la política tan indecisa que el agente prefiere quedarse suspendido, evitando el -100 del choque pero renunciando al $+100$ del aterrizaje, cayendo en un óptimo local indeseado.

Al **calibrar** la entropía a un valor diez veces menor ($\beta = 0,001$), el problema desaparece casi por completo: la duración vuelve a 295 pasos (el agente se compromete de nuevo al aterrizaje) y la recompensa se recupera hasta 228,32 con un 84 % de resolución, prácticamente a la par del baseline. La Figura 10 ilustra cómo la curva de entropía alta (naranja) se estanca por debajo, mientras que la de entropía baja (verde) acompaña al baseline por encima de 200.

La conclusión es doble. Primero, la normalización y la entropía son herramientas útiles pero **sensibles a su calibración**: un coeficiente mal elegido puede inducir patologías de comportamiento que degradan el rendimiento por debajo de la versión base. Segundo, y más importante, **la mejora verdaderamente decisiva fue la línea base**, no las opcionales: una vez que el Actor-Crítico dispone de una señal de ventaja informativa, las mejoras adicionales aportan poco e incluso pueden restar si se aplican sin cuidado.

4. Comparación Global

Tabla 10: Comparación global – todos los métodos (evaluación, 100 episodios)

Método	Recomp. Media	Desv. Est.	Duración Media	Resuelto (≥ 200)
Política aleatoria	-183,18	119,75	90,34	No (0 %)
REINFORCE (vanilla)	-39,90	50,90	126,00	No (0 %)
REINFORCE + mejoras, $\beta = 0,01$	118,64	65,49	957,72	No (0 %)
REINFORCE + mejoras, $\beta = 0,001$	104,08	56,23	775,28	No (0 %)
REINFORCE + línea base	237,06	76,93	271,65	Sí (87 %)
REINFORCE + línea base + mejoras, $\beta = 0,01$	157,22	79,94	706,47	Parcial (37 %)
REINFORCE + línea base + mejoras, $\beta = 0,001$	228,32	89,01	295,72	Sí (84 %)




Figura 11: Comparación de las curvas de entrenamiento de REINFORCE puro (azul) y con línea base (naranja), media móvil de 50 episodios. La línea base domina de forma consistente y cruza el umbral de 200, mientras la versión pura se mantiene en territorio negativo.




Figura 12: Distribución de la recompensa en evaluación (100 episodios) para los siete agentes. Los triángulos verdes marcan la media. Solo el baseline y su variante de entropía baja sitúan su caja por encima del umbral de 200.

El **método ganador es REINFORCE con línea base** en su versión obligatoria, con 237,06 de recompensa media y un 87 % de episodios resueltos (Tabla 10). Es el único que sitúa su media claramente por encima del umbral, seguido muy de cerca por su variante de entropía baja (228,32, 84 %). El boxplot (Figura 12) lo confirma visualmente: solo estas dos configuraciones tienen la caja completa por encima de 200.

Sobre la **reducción de varianza**: como se ha discutido, la línea base la redujo de forma modesta en entrenamiento (175,42 $\rightarrow$ 160,23). El efecto más visible no está en la dispersión episodio a episodio sino en la **velocidad y altura de convergencia** (Figura 11): el baseline cruza los 200 puntos en torno al episodio 900 y se mantiene, mientras que REINFORCE puro permanece en territorio negativo durante los 2000 episodios. En cuanto a las **mejoras opcionales**, su aportación es ambigua y depende críticamente de la calibración: bien ajustadas (entropía baja) igualan casi al baseline, pero mal ajustadas (entropía alta) lo degradan notablemente por el efecto de flotado.

Finalmente, sobre la **transformación del comportamiento**: la progresión a lo largo de la práctica ilustra perfectamente cómo el gradiente de política convierte la aleatoriedad en inteligencia. El agente aleatorio (−183) actúa sin relación entre estado y acción; REINFORCE puro (−40) aprende a evitar el desastre inmediato pero no a completar la tarea; y el Actor-Crítico (+237) aprende la política fina de frenado y orientación que conduce a un aterrizaje seguro. La clave de ese salto final no fue más cómputo ni más parámetros, sino una **señal de aprendizaje mejor estructurada**: la ventaja, que indica al agente no si una trayectoria fue buena en absoluto, sino si cada acción fue mejor de lo esperado.

5. Conclusiones

- **Agente aleatorio**: con una recompensa media de −183,18, queda a más de 383 puntos del umbral de resolución. Confirma la dificultad del entorno y sirve de referencia objetiva: sin aprendizaje, la tarea es inabordable.
- **REINFORCE vanilla**: demuestra capacidad de aprendizaje (mejora hasta −39,90 en evaluación) pero su alta varianza, derivada de escalar el gradiente por el retorno de la trayectoria completa, le impide converger de forma estable y nunca alcanza los 200 puntos.
- **Línea base (Actor-Crítico)**: es la mejora decisiva de la práctica. Al sustituir el retorno por la ventaja $A_t = G_t - V(s_t)$, transforma un agente que no resuelve nunca en uno que aterriza con éxito el 87 % de las veces (237,06 de media). Su efecto principal es volver informativa la señal de aprendizaje, más que reducir drásticamente la varianza (que baja solo de 175,4 a 160,2).
- **Mejoras opcionales**: la normalización y el bonus de entropía son útiles pero muy sensibles a su calibración. Un coeficiente de entropía excesivo ($\beta = 0,01$) induce un óptimo local de “flotar sin aterrizar” (706–957 pasos por episodio) que degrada el rendimiento; reducirlo a $\beta = 0,001$ recupera casi por completo el resultado del baseline. La lección es que *una mejora mal calibrada puede empeorar el modelo*.
- **Aprendizajes**: esta práctica me ha mostrado que en RL profundo el éxito no depende tanto de la potencia de cómputo como del **diseño de la señal de aprendizaje**: la varianza del gradiente, la calidad de la estimación de valor y la calibración de los términos de regularización determinan por completo si el agente resuelve o no la tarea. También he comprobado de primera mano la enorme sensibilidad del RL a los hiperparámetros y la importancia de interpretar las métricas con criterio: una duración de episodio anormalmente alta reveló un comportamiento patológico (el flotado) que la recompensa media por sí sola no dejaba ver. Como líneas de trabajo futuro, sería natural explorar algoritmos más avanzados como A2C/A3C (que actualizan en línea en lugar de por Monte Carlo) o PPO (que limita el tamaño de cada actualización de política), así como la estimación de ventaja generalizada (GAE) para un mejor compromiso sesgo-varianza.